

Predicción de Inventario



Proyecto de Machine Learning aplicado a la previsión de demanda diaria por producto

López, Teresa · Martínez García, Raquel · Madriz Valero, Ali Manuel

Contenido

- 01 Contexto y Objetivos del Proyecto
- 02 Datos y Análisis Exploratorio
- 03 Selección de Productos y Feature Engineering
- 04 División Temporal y Comparación de Modelos
- 05 Optimización y Selección del Modelo Final
- 06 Evaluación e Interpretabilidad (SHAP)
- 07 Conclusiones y Trabajo Futuro

01 Contexto del Problema de Negocio

La papelería Trazos y Hojas repone inventario de forma intuitiva. El objetivo es comprobar si el histórico de ventas del TPV permite anticipar, de forma objetiva, cuántas unidades se necesitarán de cada producto.

6 meses

histórico de ventas del TPV

1.012

productos en el catálogo

31

productos aptos para modelar

69,2%

de días sin venta (ceros)

Pregunta del proyecto

¿Es posible predecir la demanda diaria de los productos de una papelería utilizando Machine Learning y un histórico de ventas de seis meses?

Tipo de problema: regresión supervisada sobre datos de panel (producto x día) · Variable objetivo: Unidades_Vendidas · Métrica principal: RMSE (con MAE y R^2 de apoyo)

— Recorrido del Proyecto

1

Ventas del TPV (detalle línea a línea)

2

Agregación diaria por producto → target: Unidades_Vendidas

3

Selección de productos aptos (3 reglas de viabilidad)

4

Feature Engineering (calendario · lags · estadísticas móviles)

5

División temporal (train / test · validación cruzada por fechas)

6

Comparación de modelos (RandomForest · CatBoost · LightGBM)


7

Optimización de hiperparámetros (Optuna) y selección final

8

Evaluación + Interpretabilidad (SHAP)

02 Datos y Análisis Exploratorio




● Demanda intermitente

La mayoría de combinaciones producto-día no registran venta; el target está concentrado en cero.

● Escalas muy dispares

Copias A4 venden cientos de unidades/día; el resto del catálogo no llega a una unidad diaria.



● Patrón semanal

La demanda oscila de forma regular según el día de la semana.

● Catálogo largo, demanda esporádica

De 1.012 productos, la mayoría se vende de forma demasiado ocasional para modelarse.

03 Selección de Productos Aptos

No tiene sentido predecir la demanda de un producto vendido tres veces en seis meses: no hay señal que aprender. Se exigen tres reglas simultáneas de viabilidad:

Regla	Criterio	Motivo
Volumen	≥ 30 transacciones en el periodo	Evita que el modelo memorice en lugar de aprender un patrón
Regularidad	Venta en ≥ 15 de 25 semanas	Garantiza presencia también en el periodo de test
Estabilidad	Coef. de variación semanal $< 1,2$	Descarta productos erráticos que solo aportan ruido

31 de 1.012
productos

cumplen las tres reglas y constituyen el universo de modelado

31 productos $\times$ 169 días = 5.239 filas

Los días sin venta se completan explícitamente con cero: "no se vendió nada" es información real y relevante, no un dato ausente.

04 Feature Engineering

Los datos brutos del TPV solo contienen qué se vendió y cuándo. Toda la capacidad predictiva depende de las variables construidas a partir de ese histórico.

1

Variables de Calendario

Capturan la estacionalidad de la demanda.

- Dia_semana
- Fin_de_semana
- Dia_mes
- Mes
- Semana_year

2

Lags (retardos)

Recogen el histórico inmediato de cada producto.

- lag_1 — unidades vendidas el día anterior
- lag_7 — mismo día de la semana anterior

3

Estadísticas Móviles

Resumen del comportamiento reciente, suavizando el ruido.

- media_movil_7 / media_movil_14
- std_movil_7 — volatilidad reciente
- tendencia_7_14 — aceleración / desaceleración

Nota metodológica clave: todas las variables temporales se calculan con shift(1) antes de la ventana móvil, garantizando que el modelo solo usa información estrictamente anterior a cada día (evita data leakage).

05 División Temporal y Validación Cruzada

En un problema con estructura temporal, la división train/test no puede ser aleatoria: un split aleatorio dejaría entrenar con datos del futuro para predecir el pasado.

TRAIN — entrenamiento

**TEST
(3 semanas)**

El conjunto de test permanece completamente aislado durante todo el desarrollo y solo se usa una única vez, en la evaluación final.

Validación cruzada temporal

Al ser un panel de datos (31 productos x N fechas), una validación cruzada estándar cortaría por posición de fila y acabaría separando por producto en lugar de por tiempo. Se implementa una función que corta explícitamente por fechas únicas: todas las filas de un mismo día caen siempre en el mismo lado del split. Cada fold entrena con el pasado y valida con el futuro inmediato, con una ventana de entrenamiento que crece progresivamente — la fecha máxima de entrenamiento es siempre anterior a la mínima de validación.

06 Selección de Variables

Se evaluaron seis subconjuntos de variables (lista_1 ... lista_6), obtenidos mediante métodos de selección con lógicas distintas — el objetivo es identificar el mejor equilibrio entre capacidad predictiva e interpretabilidad.

Conjunto	Método	Lógica
lista_1	Tests estadísticos (Spearman + Kruskal-Wallis)	Relación univariante de cada variable con el target
lista_2	Información mutua	Dependencia de cualquier tipo, no solo lineal
lista_3	SelectFromModel	Importancia en un RandomForest, por encima de la media
lista_4	RFE	Eliminación recursiva de la variable menos importante
lista_5	SFS	Búsqueda greedy que añade variables una a una
lista_6	Consenso (hard voting)	Variables elegidas por al menos 3 de los 5 métodos

La elección final no se basa en el criterio de un método concreto: los seis se comparan midiendo su rendimiento real sobre los modelos.

07 Comparación de Modelos

Modelos evaluados

Modelo	Rol
DummyRegressor	Baseline — predice la media
RandomForest	Ensemble por bagging, robusto al ruido
CatBoost	Gradient boosting con categóricas
LightGBM	Gradient boosting de alto rendimiento

Transformación log1p del target

El target presenta fuerte asimetría (muchos ceros, picos altos). Se aplica log1p al entrenar, revirtiendo con expm1 al predecir.

MAE: 5,93 → 4,62 (−22%)

Desviación estándar del R^2 entre folds: 0,138 → 0,063 (más del doble de estabilidad)

El RMSE no mejora porque sigue dominado por los picos de alta rotación, que la transformación comprime deliberadamente.

Conclusión de la comparativa

- **Todos los modelos superan al baseline**
(DummyRegressor, RMSE $\approx$ 30,7 con $R^2 \approx$ 0): aprenden un patrón real.
- LightGBM obtiene el mejor resultado, con un tiempo de entrenamiento mínimo — se selecciona para optimización.

08 Optimización de Hiperparámetros

LightGBM obtuvo el mejor rendimiento inicial con un coste computacional muy inferior a sus competidores. Se compararon dos estrategias de búsqueda.

Método	RMSE (CV)
Sin optimizar (parámetros por defecto)	24,43
RandomSearch	24,35
RandomSearch → GridSearch	24,19
Optuna (optimización bayesiana)	24,16

Optuna obtiene el mejor resultado y es más eficiente: se adopta como método definitivo.

La mejora frente al modelo por defecto es reducida (~1%): un hallazgo relevante — el rendimiento está limitado por la naturaleza del problema (demanda intermitente, muchos ceros, escalas dispares), no por la configuración de hiperparámetros.

09 Selección del Modelo — Hallazgo Clave

El conjunto ganador inicial (lista_5, vía SFS) no incluye ninguna variable de tipo lag ni media móvil.

Se apoya casi solo en calendario y producto — ignora el histórico reciente de ventas, difícil de defender en previsión de demanda. Se optimizan de forma independiente lista_1, lista_4 y lista_6 (100 trials cada una) y se evalúan sobre test.

Lista	RMSE (CV)	RMSE (test)	MAE (test)	R ² (test)
lista_1	24,52	24,77	4,12	0,322
lista_6	24,69	24,57	4,00	0,333
lista_4	24,76	23,99	4,05	0,364

El orden en validación se invierte por completo en test: lista_4 (peor en CV) generaliza mejor y da el modelo más preciso del proyecto → se selecciona como conjunto definitivo.

10 Modelo Final y Evaluación


Modelo	RMSE	MAE	R ²
DummyRegressor (baseline)	30,66	10,06	≈ 0
LightGBM · lista_5 (sin lags)	25,23	4,39	0,297
LightGBM · lista_4 (con lags)	23,99	4,05	0,364

¿Por qué el RMSE es tan alto comparado con el MAE?

Porque el RMSE penaliza al cuadrado y unos pocos errores muy grandes en la copistería (que venden cientos de unidades) lo dispararán. El MAE de 4 unidades refleja mejor el error habitual en el grueso del catálogo.


11 Interpretabilidad

Importancia de variables



El modelo se apoya sobre todo en variables temporales — medias móviles, lags y volatilidad — junto con Dia_semana.

SHAP — sentido del efecto



lag_1 y medias móviles altos empujan la predicción al alza. Dia_semana tiene efecto bidireccional, confirmando el patrón semanal.

12 Conclusiones y Trabajo futuro

¿Es posible predecir la demanda diaria con ML y seis meses de histórico?

Sí, con matices: error medio ≈ 4 unidades por predicción y $\sim 36\%$ de la variabilidad explicada sobre datos completamente nuevos.

Elemento	Resultado
Algoritmo	LightGBM
Variables	lista_4 — lags, medias móviles, volatilidad y día de la semana
Transformación del target	log1p (revertida con expm1)
Validación	Cruzada temporal por fechas (5 folds)
RMSE / MAE / R ² (test)	23,99 / 4,05 / 0,364

Limitaciones

- Histórico corto: 6 meses no capturan la estacionalidad anual (vuelta al cole, Navidad).
- Catálogo reducido: solo 31 de más de mil productos cumplen los criterios de viabilidad.
- Error concentrado en los productos de alta rotación, los peor predichos en términos absolutos.

Trabajo futuro

- Ampliar el histórico a 1-2 años para capturar la estacionalidad anual.
- Incorporar variables externas: festivos, calendario escolar, promociones.
- Modelar por separado los productos de alta rotación.
- Reentrenar con el histórico completo (train + test) de cara a producción.



Trazos y Hojas

Predicción de Inventario mediante Machine Learning

López, Teresa · Martínez García, Raquel · Madriz Valero, Ali Manuel